

AgroSearch — Motor de Busca Inteligente

Relatório Técnico de Recuperação de Informação e NLP

Instituição: UNIPÊ — Centro Universitário de João Pessoa

Disciplina: Tópicos Avançados (RI / NLP)

Professor: Me. Ricardo Roberto de Lima

Equipe: Mateus Ieno Ramalho, Heitor de Oliveira Mamede, Júlio César Carvalho Santos

Auxílio: Antigravity (Gemini 3.8 Flash)

1. Arquitetura da Solução

A solução AgroSearch foi desenvolvida em Python e estruturada através do framework Streamlit para prover uma interface analítica interativa para a AgroTech Solutions. O sistema endereça a problemática de recuperação de informações em manuais agrícolas técnicos através de uma implementação estrita 100% 'from scratch' (sem bibliotecas de alto nível como scikit-learn), unindo o modelo TF-IDF clássico ao modelo vetorial através de um pipeline em 4 etapas principais mais o ranqueamento bônus:

1. Ingestão e Pré-processamento: O texto passa por normalização Unicode (remoção de acentos via NFKD), segmentação em tokens alfanuméricos por regex, filtro de mais de 160 stopwords em português e algoritmo próprio de Stemming morfológico (reduzindo flexões como 'irrigação' e 'irrigar' ao radical comum 'irrig'). A interface permite calibrar dinamicamente a ativação de Stemming e Stopwords via checkboxes.

2. O Índice Invertido em Memória: Estruturado sob a forma Termo -> [IDs de Docs], mapeando cada token limpo aos documentos onde ocorre e suas frequências locais. A aplicação expõe a visualização tanto em tabela interativa (st.dataframe) quanto na hierarquia nativa JSON (st.json).

3. Motor Léxico TF-IDF (From Scratch): Calcula a frequência relativa do termo $TF(t, d) = f(t, d) / |d|$ e o IDF suavizado $IDF(t) = \log_{10}(N / DF(t)) + 1.0$, garantindo normalização pelo comprimento do texto e pesos discriminativos rigorosamente positivos sem viés para documentos extensos.

4. Ranqueamento por TF-IDF Acumulado: A convergência de relevância básica soma os pesos dos termos da query presentes no documento sob a fórmula:

$$Score_TFIDF(q, d) = \sum [TF(t, d) \times IDF(t)] \quad (\text{para todo } t \text{ pertencente a } q \text{ e } d)$$

5. Similaridade de Cosseno (Desafio Bônus): Modelo vetorial completo no qual a query q e os documentos d são projetados no espaço multidimensional, normalizando pelas normas euclidianas para consultas compostas:

$$CosineSim(q, d) = (q \cdot d) / (||q|| \times ||d||) = \sum [w(t, q) \times w(t, d)] / [\sqrt{\sum w(t, q)^2} \times \sqrt{\sum w(t, d)^2}]$$

2. Comparação de Ranks (Gráfico / Tabela)

A eficiência dos modelos de ranqueamento em priorizar documentos que combinam múltiplos conceitos técnicos pode ser observada na Matriz Comparativa para a query "irrigação na soja":

ID Documento	Título / Conteúdo Resumido do Manual	Rank TF-IDF	Rank Cosseno	Rank Final
Doc 1	A soja requer irrigação constante durante floração...	1	1	1 *
Doc 5	A irrigação por gotejamento economiza água orgânica...	3	2	2
Doc 2	O controle biológico de lagartas na soja...	2	3	3
Doc 4	Lagartas desfolhadoras causam grande prejuízo na soja...	4	4	4
Doc 3	A adubação verde com leguminosas melhora o milho...	5 (zero)	5 (zero)	5

Análise qualitativa: O TF-IDF acumulado e a Similaridade de Cosseno convergem elegendo o Doc 1 como Documento Vencedor absoluto, pois é o único a conter simultaneamente ambos os conceitos técnicos ('irrig' e 'soja'). Entre os manuais de correspondência parcial, o modelo de Cosseno penalizou a dispersão temática e priorizou o Doc 5 (focado exclusivamente em manejo hídrico) em relação ao Doc 2. O Doc 3 obteve score nulo em ambos os motores devido à ausência estrita dos tokens consultados.